ONCFM

Organisation nationale de lutte contre le faux-monnayage

Création d’un algorithme de détection automatique de faux billets

Rémy Maupetit
Data Analyst
Janvier 2026

Sommaire

- Contexte du projet Slide 3
- Objectif et source du projet Slide 4
- Analyse exploratoire des données Slides 5 et 6
- Prétraitement des données Slide 7
- Modélisation Slide 8
- Régression logistique Slides 9 et 10
- KNN Slides 11 et 12
- Random Forest Classifier Slides 13, 14 et 15
- K-means Slides 16 et 17
- Sélection du modèle le plus adapté Slides 18 et 19
- L'application fonctionnelle Slide 20
- Conclusion Slide 21

Contexte du projet

Qui?

Organisation publique

Pourquoi?

Lutte contre
le faux-monnayage

ONCFM

Comment?

Mise en place de méthodes de détection automatique basées sur les données

Objectif du projet

🎯 Mise en place d'un algorithme de détection des faux billets

- Exploiter les caractéristiques géométriques des billets
- Différencier automatiquement les billets authentiques des faux
- Déployer un modèle utilisable par une machine de contrôle spécialisée

Source du projet

❖ Fichier source : billets.csv

- 1500 billets
- Variables mesurées (en mm):
  - Longueur
  - Hauteur droite et Hauteur gauche
  - Marge haute, Marge basse
  - Diagonale
- Variable cible : nature du billet (Vrai/Faux)

Analyse exploratoire des données

- **Logiciel utilisé : *Notebook Jupyter (langage python)***
- **Répartition équilibrée mais réaliste des classes**
  - **1000 vrais billets**
  - **500 faux billets**
- **Présence de 37 valeurs manquantes dans la variable *margin_low***
- **Choix d'une imputation par régression linéaire**
- **Après imputation:**
  - **0 donnée manquante**
  - **Jeu de données complet**

Distribution des dimensions en fonction du type de billets

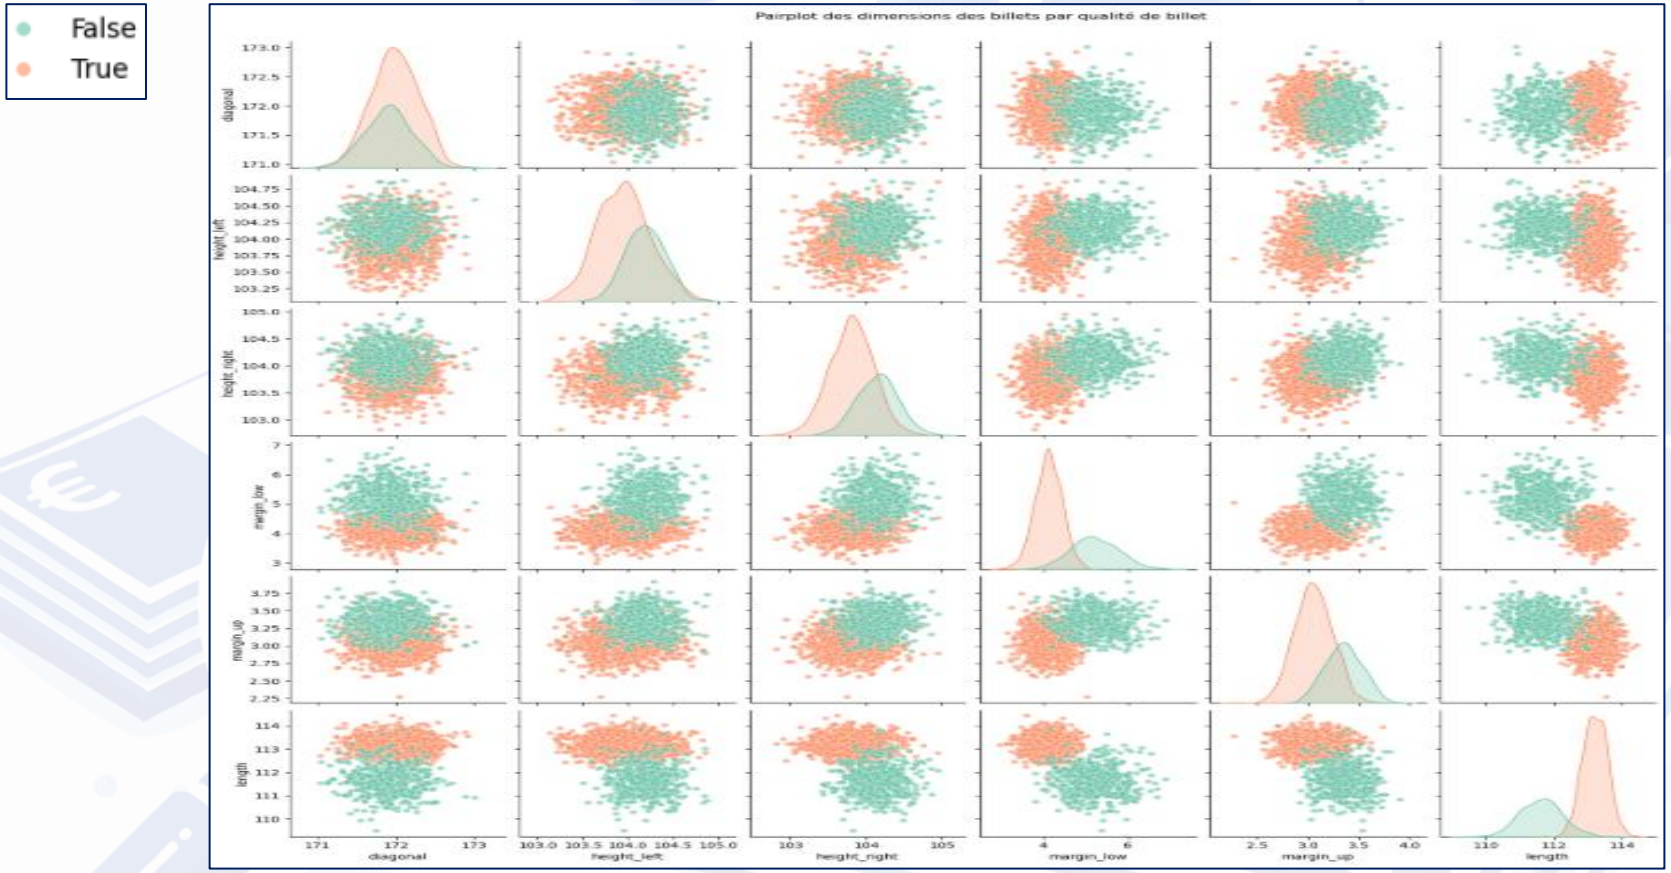

Prétraitement des données

- **Définition des variables :**
  - X = variables explicatives (mesures des billets)
  - y = variable cible (vrai ou faux billets)
- **Séparation du jeu de données :**
  - Entrainement sur 80% du jeu de données
  - Test sur les 20% restant
- **Standardisation des variables**
  - Nécessaire pour les modèles sensibles aux échelles (régression logistique, knn)

Modélisation

Objectifs :

- ❖ **Tester plusieurs modèles de classifications**
  - Régression Logistique
  - K-nearest neighbors (KNN)
  - Random Forest classifier
  - K-Means (non supervisé)

- ❖ **Identifier le modèle le plus performant pour la détection des faux billets**

Régression Logistique

❖ **Etape 1 : Entraînement du modèle réduit de 2 colonnes de données**

- Mise à l'écart des données des colonnes *diagonal* et *height_left*

❖ **Etape 2 : Prédictions sur données test**

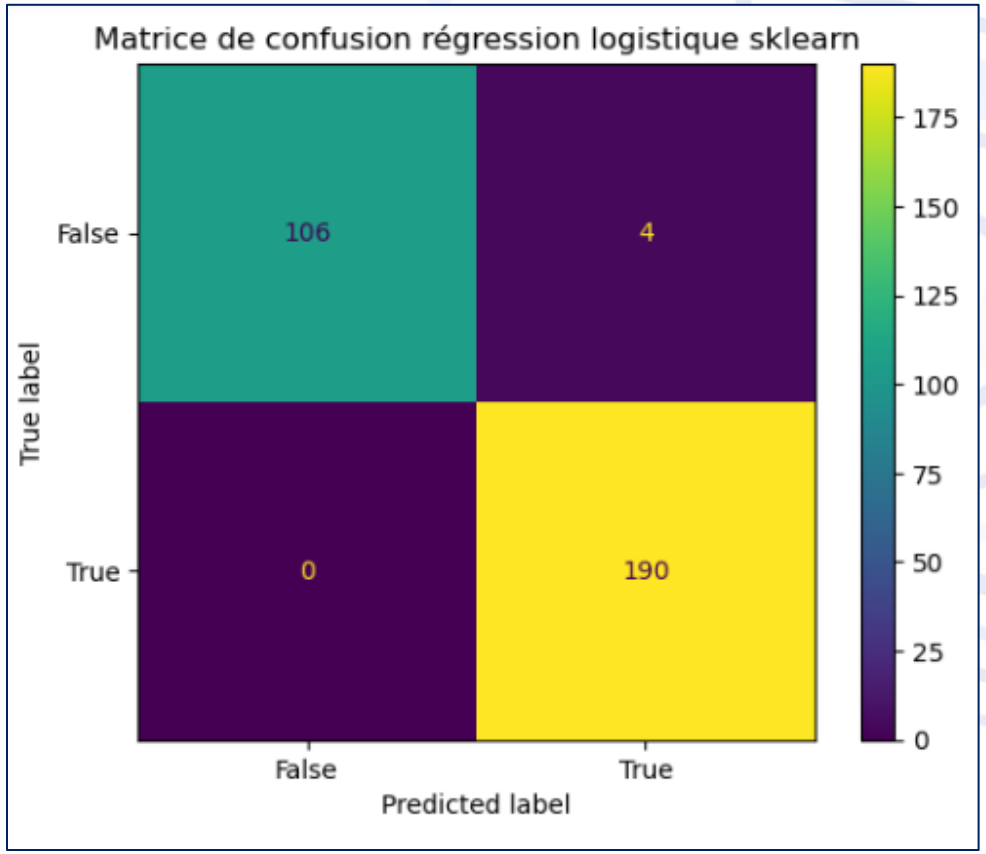

Résultats :

- Faux billets correctement détectés : 106 / 110
- Faux billets classés à tort comme vrais : 4
- Vrais billets classés à tort comme faux : 0
- Vrais billets correctement détectés : 190 / 190

Interprétations :

- Modèle assez performant.
- Quelques erreurs (4 faux prédits vrais)
- Nécessité d'améliorer les prédictions sur les faux billets

❖ Etape 3 : Améliorer le modèle en ajustant le seuil de décision

- **Seuils optimal retenu: 0,74**

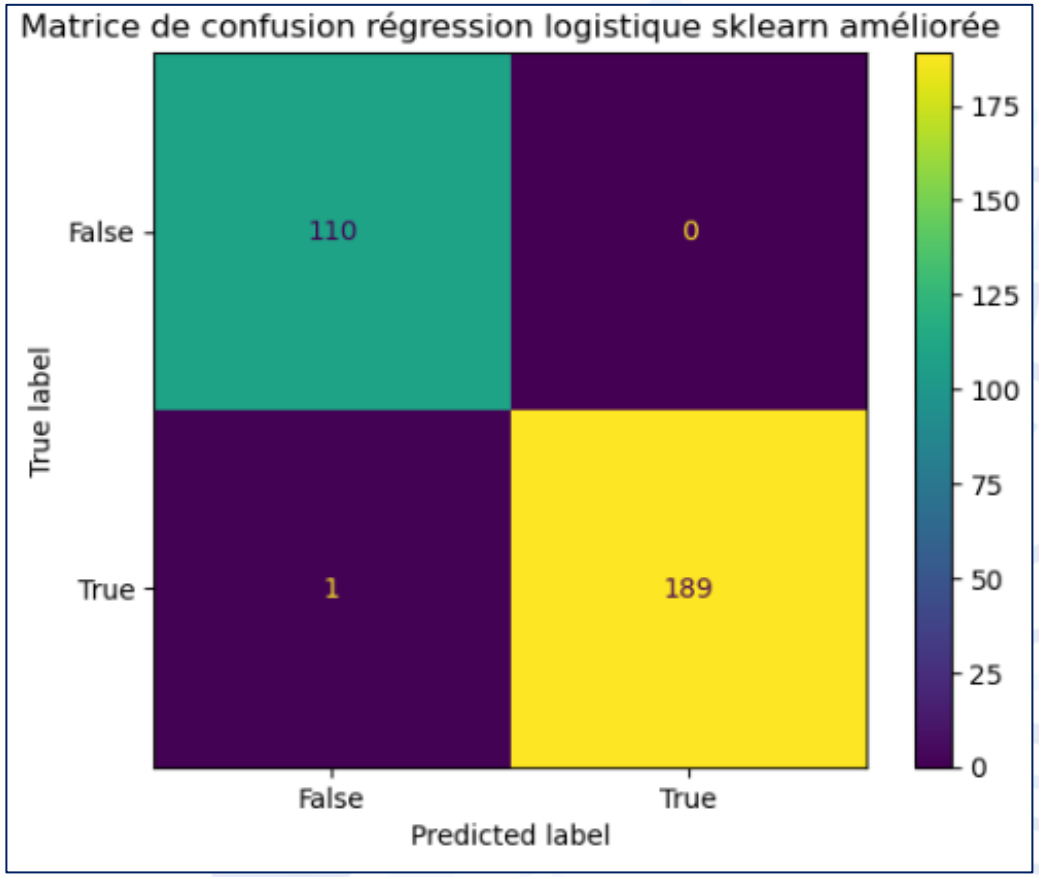

Résultats après optimisation

- Faux billets correctement détectés : 110 / 110
- Faux billets classés à tort comme vrais : 0
- Vrais billets classés à tort comme faux : 1
- Vrais billets correctement détectés : 189 / 190

Interprétation après optimisation

➢ Le modèle présente d'excellentes performances avec 1 seule erreur de classification (1 vrai billet prédit comme faux)

K-nearest neighbors (KNN)

❖ Etape 1: Définir le nombre de voisins optimal

- Nombre de voisins optimal déterminé par grid_search : 9

❖ Etape 2: Entrainement du modèle sur le jeu de données complet

❖ Etape 3: Prédictions sur données test

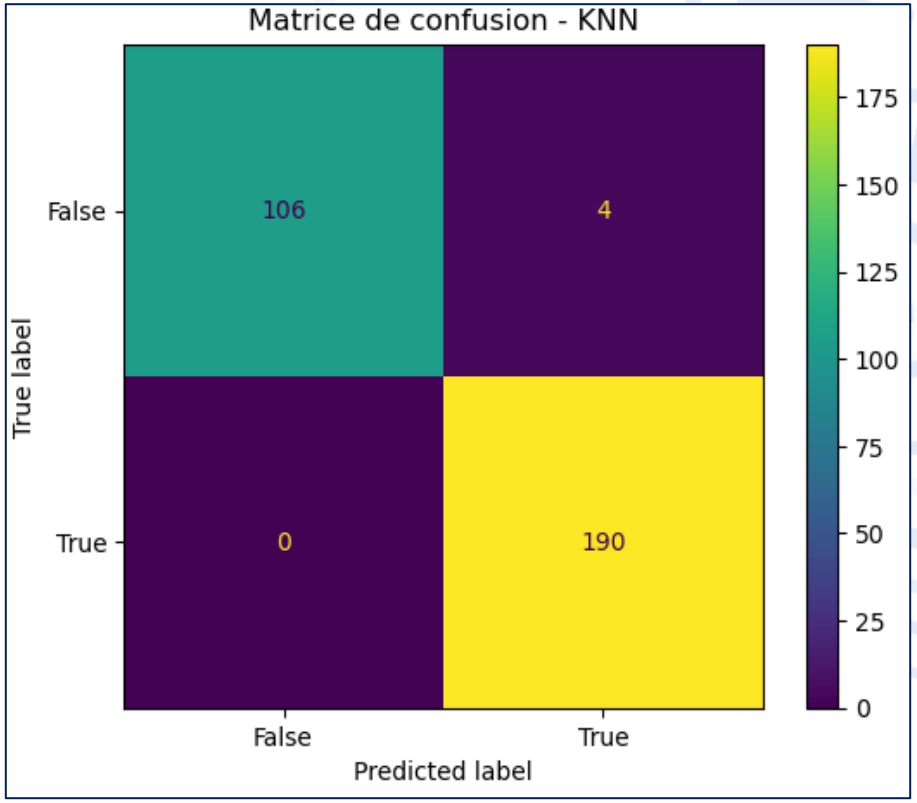

Résultats:

- Faux billets correctement détectés : 106 /110
- Faux billets classés à tort comme vrais : 4
- Vrais billets classés à tort comme faux : 0
- Vrais billets correctement détectés : 190 / 190

Interprétations:

- Modèle assez performant.
- Quelques erreurs (4 faux prédits vrais)
- Nécessité d'améliorer les prédictions sur les faux billets

❖ Etape 4 : Améliorer le modèle en ajustant le seuil de décision

- Seuil de décision optimal retenu : 0.89

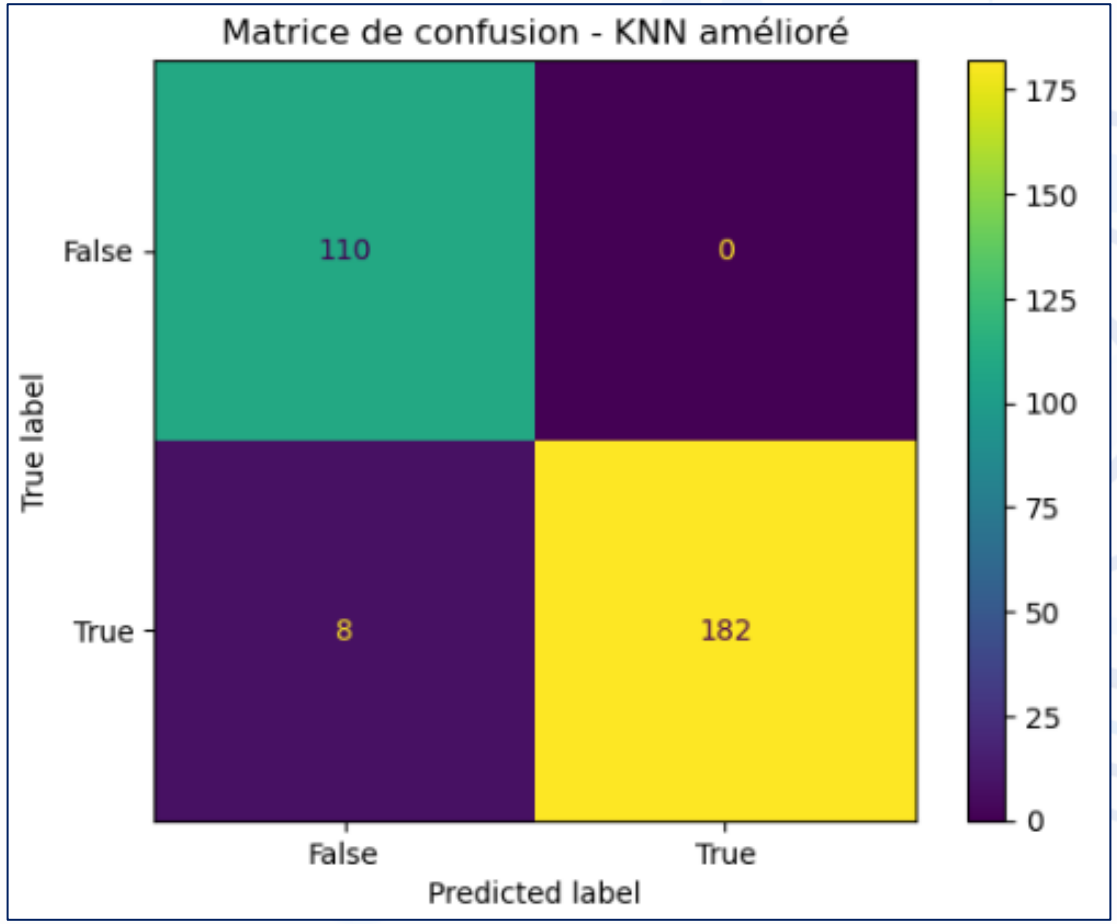

Résultats après optimisation

- Faux billets correctement détectés : 110 /110
- Faux billets classés à tort comme vrais : 0
- Vrais billets classés à tort comme faux : 8
- Vrais billets correctement détectés : 182 /190

Interprétation après optimisation

- Le modèle détecte mieux les faux billets mais des erreurs persistent.
- L'optimisation de la prédiction s'est faite au détriment de celle de la précision du classement des vrais billets

Random Forest Classifier

❖ **Etape 1 : Définition des hyperparamètres optimisés avec grid_search**

- **Meilleur combinaison nombre d'arbre et de profondeur maximum :**
  - **Nombre d'arbres : 100**
  - **Profondeur maximale optimale : 5**

❖ **Etape 2: Entrainement du modèle sur le jeu de données complet**

❖ **Exemple de forêt aléatoire**

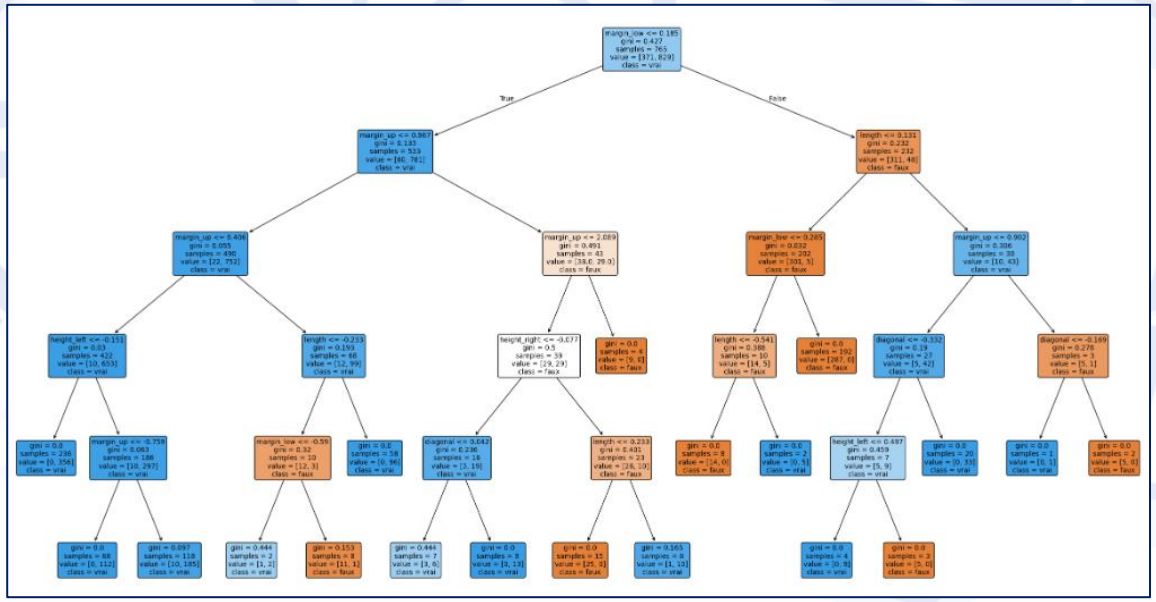

ONCFM

❖ Etape 3 : Prédiction sur données test

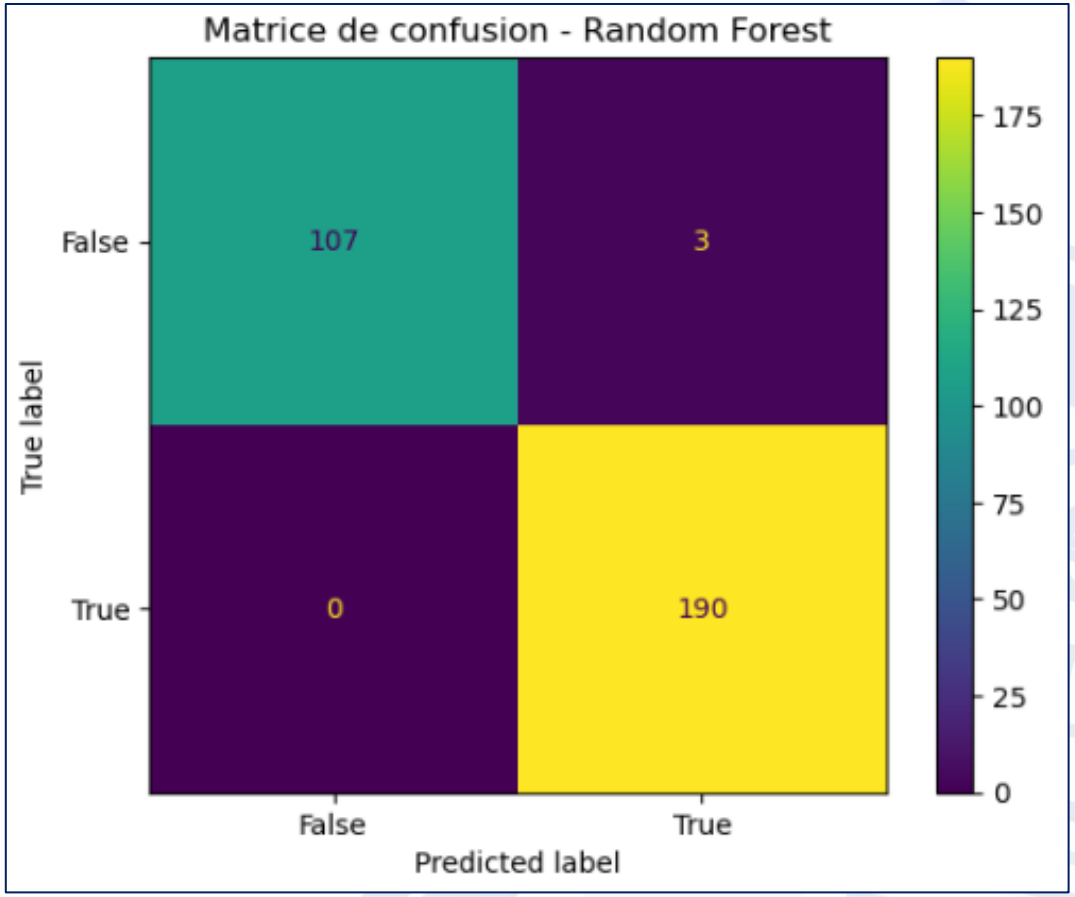

Résultats:

- Faux billets correctement détectés : 107 /110
- Faux billets classés à tort comme vrais : 3
- Vrais billets classés à tort comme faux : 0
- Vrais billets correctement détectés : 190 /190

Interprétations :

- Modèle assez performant.
- Quelques erreurs (3 faux prédits vrais)
- Nécessité d'améliorer les prédictions sur les faux billets

❖ Etape 4 : Améliorer le modèle en ajustant le seuil de décision

- **Seuil de décision retenu: 0.79**

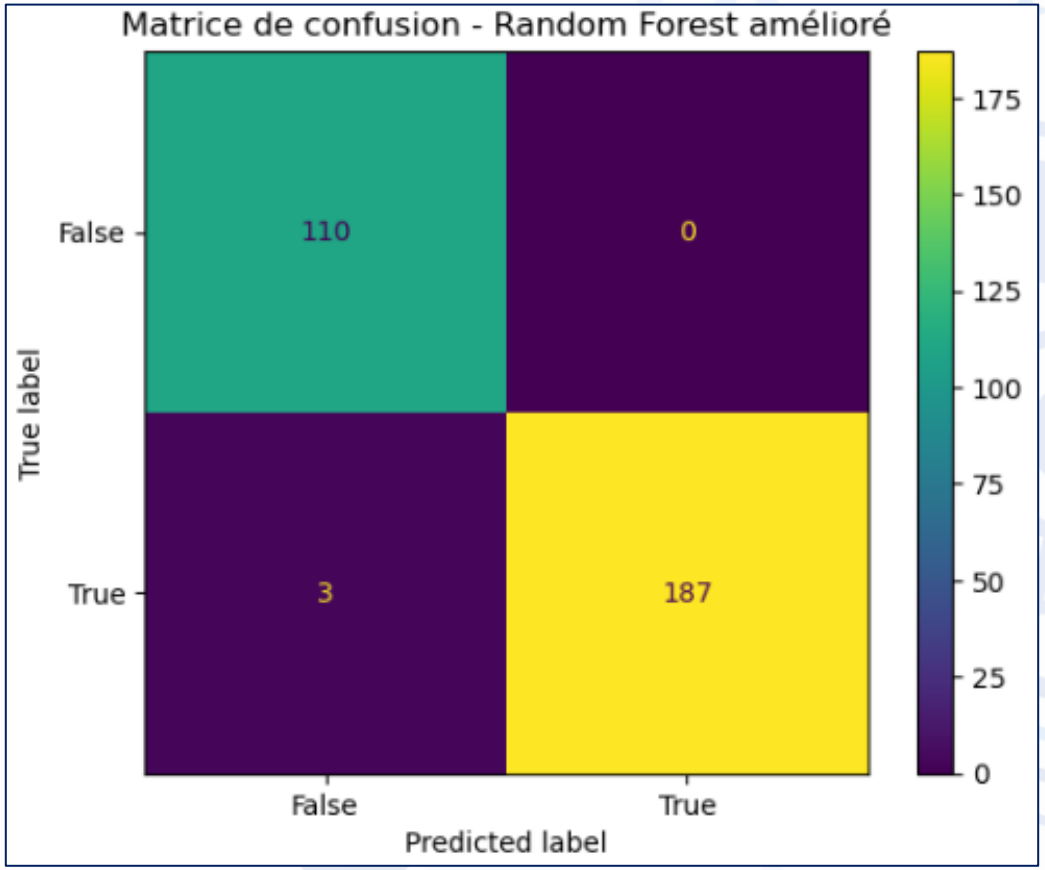

Résultats après optimisation

- Faux billets correctement détectés : 110 /110
- Faux billets classés à tort comme vrais : 0
- Vrais billets classés à tort comme faux : 3
- Vrais billets correctement détectés : 187 /190

Interprétation après optimisation

- Le modèle est très performant pour la détection des faux billets, mais il commet quelques erreurs concernant la détection des vrais billets.
- L'optimisation de la prédiction des faux billets s'est faite au détriment de celle des vrais.

KMeans

❖ **Etape 1 : Définition du nombre de clusters**

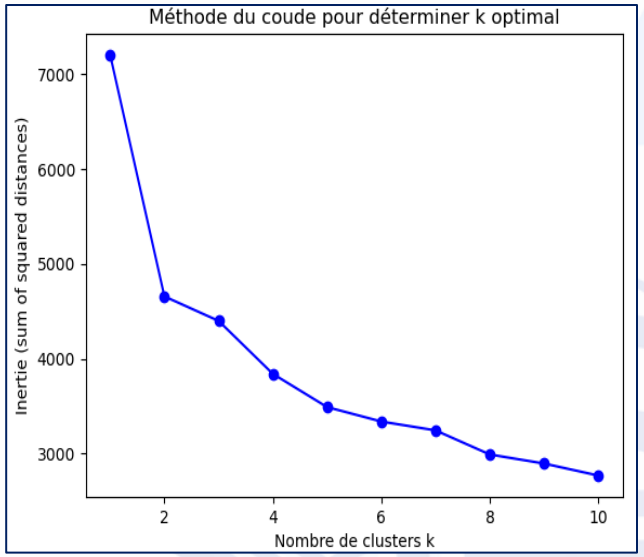

- **Nombre de clusters optimal: 2**

❖ **Etape 2 : Entraînement du modèle**

❖ **Etape 3 : Réalisation de la projection des données**

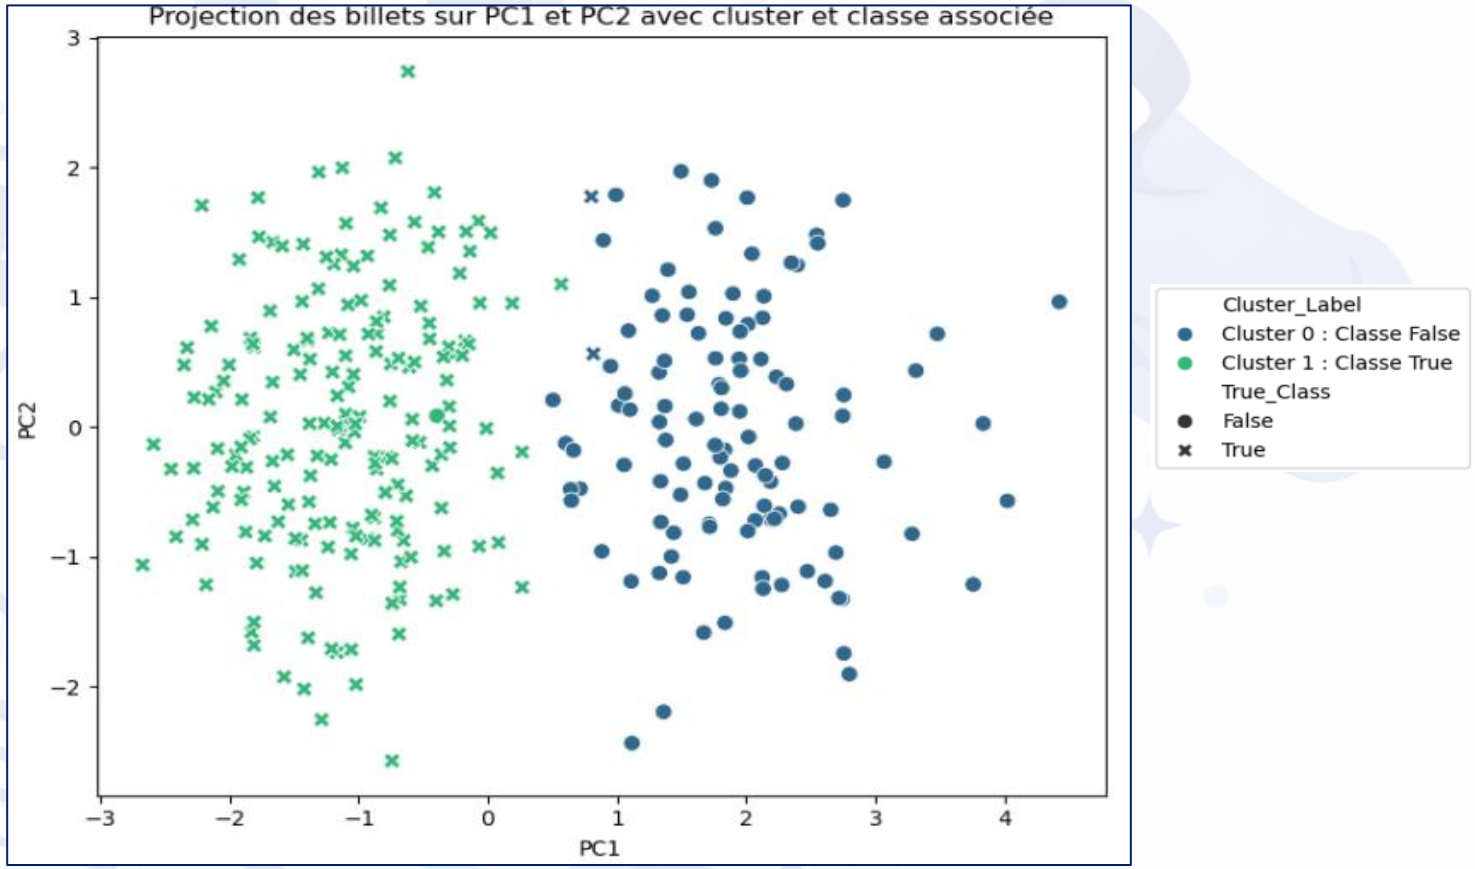

❖ Etape 3 : Prédictions sur données test

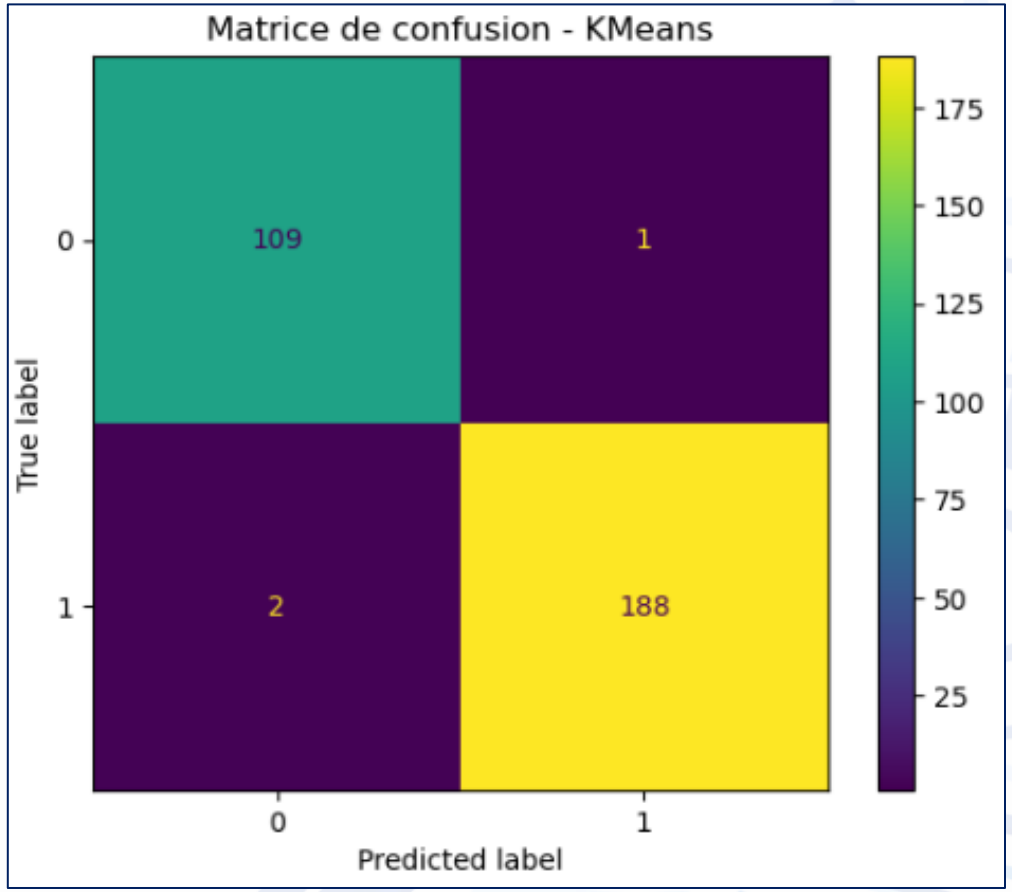

Résultats:

- Faux billets correctement détectés : 109 / 110
- Faux billets classés à tort comme vrai : 1
- Vrais billets classés à tort comme faux : 2
- Vrais billets correctement détectés : 188 / 190

Interprétations :

- Le modèle est performant pour la prédiction des faux billets, mais commet quelques erreurs dans la classification des vrais billets.
- Limites du modèle : il est non supervisé et non améliorable

Sélection du modèle le plus adapté

❖ **Critères de comparaisons:**

- **Les matrices de confusion**

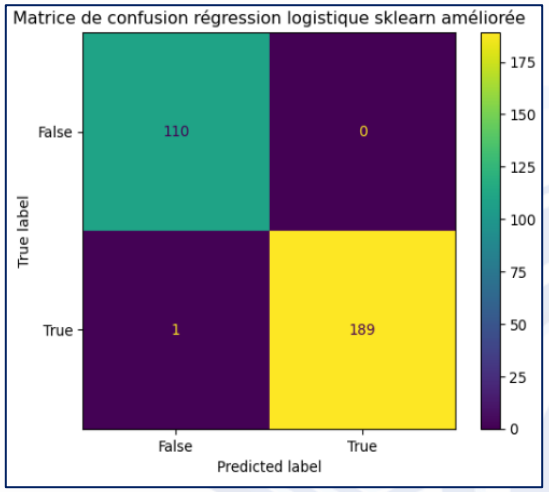

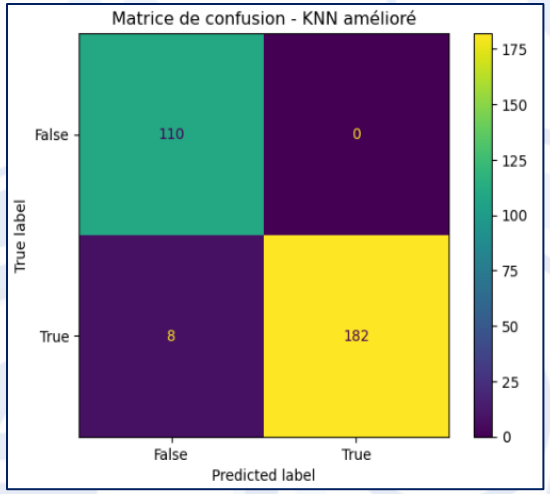

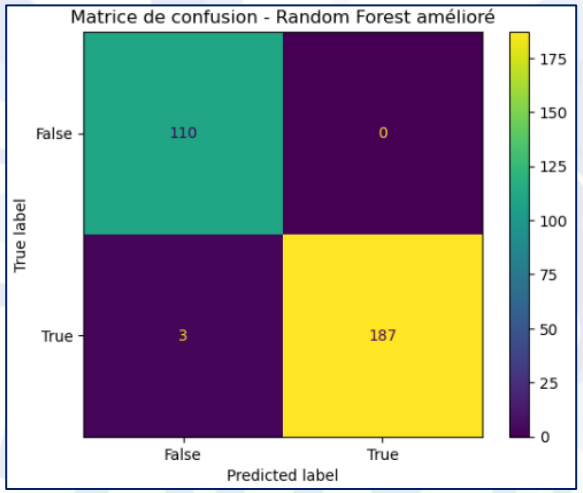

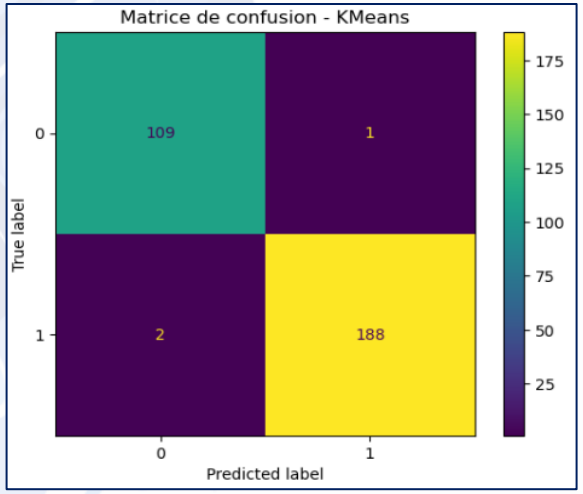

- **Les rapports de classification**

	precision	recall	f1-score	support
Régression Logistique	0.995	0.997	0.996	300.0
KNN	0.966	0.979	0.972	300.0
Random Forest	0.987	0.992	0.989	300.0
KMeans	0.988	0.990	0.989	300.0

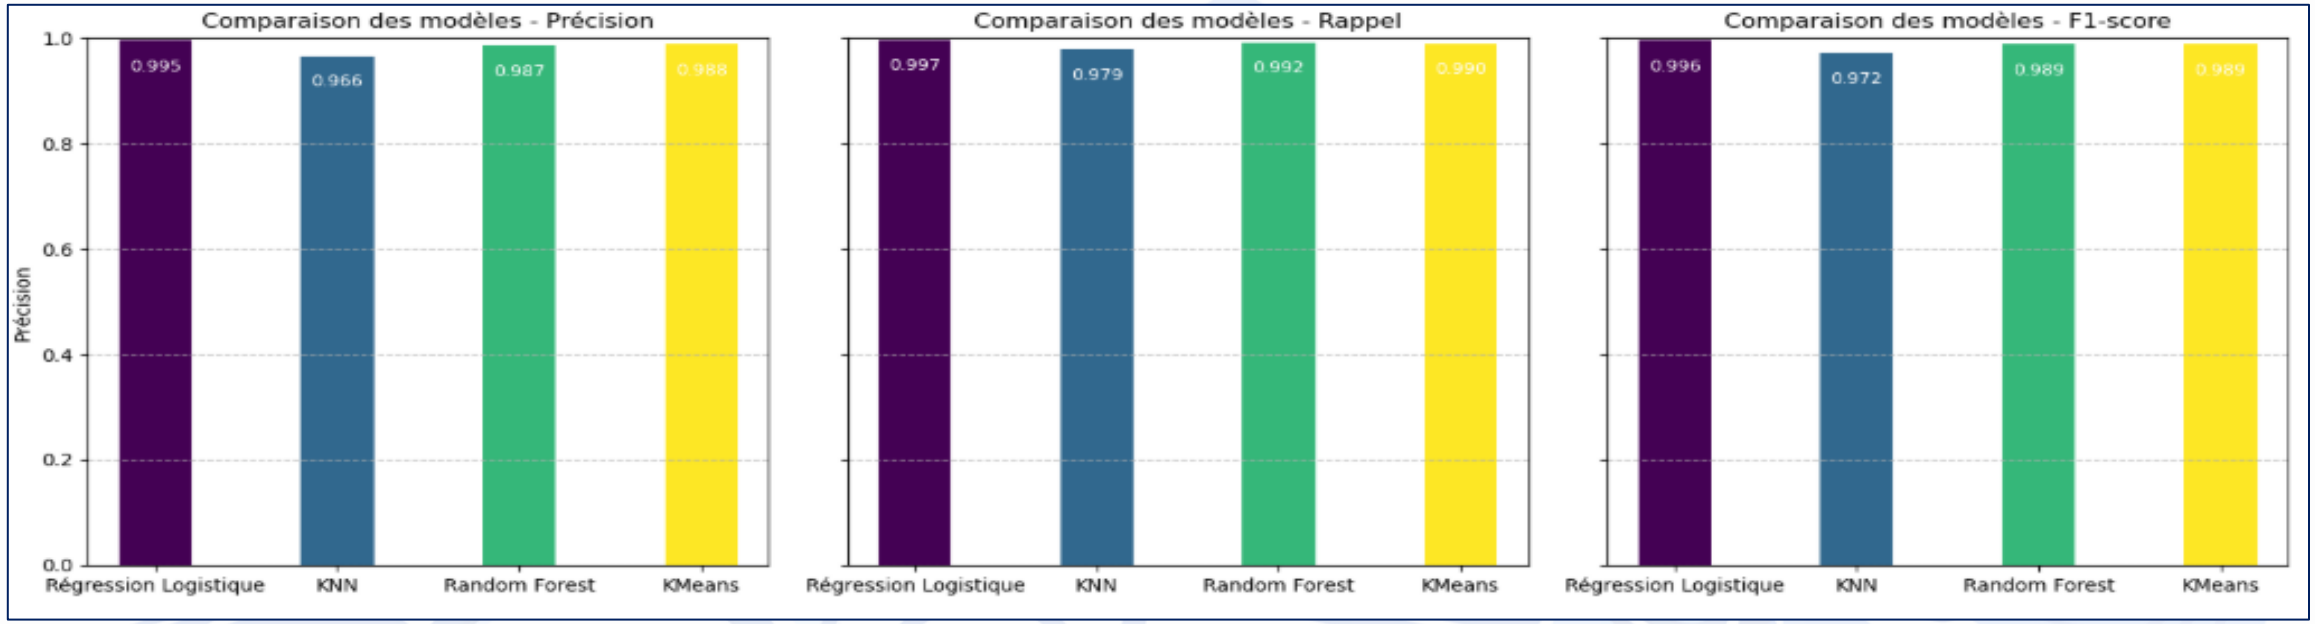

1

Régression logistique

2

Random Forest Classifier

3

KNN

4

KMeans

ONCFM

L’application fonctionnelle

❖ Composition:

- Modèle retenu : Régression logistique
- Seuil de décision appliqué : 0.74

❖ Fonctionnalités :

- Lecture de nouveaux fichiers de données
- Harmonisation automatique des variables
- Prédiction du nombre de vrais et faux billets (3 faux , 2 vrais)
- Liste des étiquettes par catégorie (A_1, A_2, A_3 = faux , A_4, A_5 = vrai)

Conclusion

❖ **Objectif atteint : détection fiable des faux billets**

- Modèle robuste et interprétable (0 faux billets laisser passé)

❖ **Perspectives :**

- Intégration de nouvelles variables
- Tests sur des données réelles supplémentaires
- Comparaison avec des modèles plus complexes

Merci de votre attention

Organisation nationale de lutte contre le faux-monnayage